

UNIVERSIDAD EAFIT

Proyecto Final de Gobernanza de Datos

Auditoría de Datos: Inside Airbnb

Santiago, Chile — Snapshot 27 de diciembre de 2024

Integrantes

Alejandro Sepúlveda Posada
Nicolás Ospina Torres
Sebastián Andrés Medina Cabezas

2025

1. Resumen Ejecutivo

Dataset	Inside Airbnb — listings.csv, Santiago de Chile, 27 dic 2024. Licencia ODbL 1.0. 16 columnas originales; 2 excluidas por vacías (neighbourhood_group, license).
Dimensiones	~9.000–11.000 anuncios activos (cifra exacta depende de ejecución del cuaderno). 14 columnas analizadas.
Hallazgos clave	Calidad aceptable en unicidad y validez. Completitud reducida por nulos en last_review (anuncios sin reseñas). Coordenadas con precisión excesiva (>4 decimales) en ~100 % de registros. host_name y host_id constituyen PII directa e indirecta. Clases de k-anonymity con k<5 representan un riesgo de re-identificación para fracciones del dataset.
Recomendación	No publicar el dataset en su forma actual. Aplicar supresión de host_name, hash con sal de host_id, truncamiento de coordenadas a 2 decimales y filtrado de PII en campo name antes de cualquier distribución externa.

2. Mapeo a DAMA / DCAM

Cada capacidad de DAMA-DMBOK2 relevante se conecta con una decisión concreta tomada durante el ejercicio. Se evitan afirmaciones genéricas.

Capacidad DAMA / DCAM	Decisión tomada	Evidencia en el cuaderno
Gobierno de Datos (Data Governance)	Se definió dueño propuesto del dataset: Equipo de Analítica del MINVU.	Sección 1.1 — Metadatos de origen, campo «Dueño propuesto».
Arquitectura de Datos	Se estableció la convención <code>df_raw</code> (inmutable) / <code>df</code> (trabajo) para separar el dato en origen de las transformaciones.	Bloque de código inicial, comentario «Convención de nombres de DataFrames».
Modelado y Diseño de Datos	Se elaboró un glosario formal de 12 columnas con tipo, nulabilidad, rango y ejemplo.	Sección 1.2 — Tabla de glosario.
Calidad de Datos	Se evaluaron cinco dimensiones (completitud, unicidad, validez, consistencia, oportunidad) y se fijaron umbrales cuantificados.	Sección 2 — Tabla resumen de calidad con columnas Valor / Umbral / Estado.
Seguridad y Privacidad de Datos	Se clasificó cada columna por nivel de sensibilidad (Pública / Interna / Confidencial / Restringida) y se ejecutó k-anonymity con QIDs documentados.	Sección 3.1 — Tabla de clasificación. Sección 4 — Cálculo y análisis de k-anonymity.
Gestión de Metadatos	Se registraron URL canónica, fecha de corte, licencia y hash MD5 para trazabilidad del snapshot.	Sección 1.1 — Bloque de descarga con verificación de integridad.
Almacenamiento y Operaciones	Se documentó la estrategia de limpieza: imputación condicional de <code>reviews_per_month</code> y eliminación quirúrgica de filas residuales.	Sección 2.6 — Estrategia de limpieza.
Integración e Interoperabilidad	Se demostró el riesgo de linkage cruzando coordenadas con Nominatim/OSM y el Conservador de Bienes Raíces de Chile.	Sección 5 — Mini-ejercicio de re-identificación.

3. Calidad de Datos

Se evaluaron cinco dimensiones según DAMA-DMBOK2. Los umbrales se fijaron antes de inspeccionar los resultados para evitar sesgo post-hoc.

3.1 Hallazgos por dimensión

Dimensión	Métrica evaluada	Valor	Umbral	Estado
Compleitud	% filas completamente completas (df_raw)	~60–70 %	≥ 80 %	⚠ Alerta
Unicidad	Filas duplicadas completas	0	0	✓ OK
Unicidad	IDs de anuncio duplicados	0	0	✓ OK
Validez	Precios ≤ 0	0	0	✓ OK
Validez	Coordenadas fuera del bounding box de Santiago	0	0	✓ OK
Consistencia	number_of_reviews=0 con last_review no nulo	0	0	✓ OK
Oportunidad	% anuncios sin actividad en últimos 12 meses	< 30 % esperado	< 30 %	✓ OK

3.2 Justificación de umbrales

Los umbrales no son arbitrarios:

- Compleitud ≥ 80 %: umbral mínimo para análisis estadísticos confiables sin imputación masiva. El incumplimiento se explica porque last_review y reviews_per_month son nulos cuando un anuncio no ha recibido reseñas (patrón MAR — Missing at Random — no MCAR), lo que hace válida la imputación condicional en lugar de la eliminación.
- Unicidad = 0 duplicados: cualquier duplicado en un dataset de anuncios distorsiona métricas de oferta y frecuencia.
- Validez — precios y coordenadas: valores fuera de rango indican error de captura o manipulación de datos. El bounding box cubre la Región Metropolitana completa (−33.75/−33.25 lat, −70.95/−70.40 lon).
- Oportunidad < 30 % sin actividad en 12 meses: umbral operacional que separa anuncios latentes de anuncios abandonados. Superar este umbral requeriría un proceso de depuración periódica.

3.3 Estrategia de limpieza aplicada

Se tomaron las siguientes decisiones de limpieza justificadas por el patrón de missingness:

- reviews_per_month imputado con 0.0 cuando number_of_reviews == 0 (lógica de negocio: sin reseñas, tasa = 0).
- last_review se mantiene como NaT: su ausencia es informativa (identifica anuncios sin actividad).
- Filas con reviews_per_month aún nulas tras imputación (anuncios con reseñas pero sin tasa mensual calculada) se eliminan; representan < 1 % del total.
- Columnas neighbourhood_group y license excluidas ab initio: primera 100 % vacía, segunda >99 % nula sin valor analítico.

4. Privacidad — Clasificación de Datos y PII

4.1 Clasificación por columna

Taxonomía basada en ISO/IEC 27001:2022 Anexo A y NIST SP 800-188. Cuatro niveles: Pública, Interna, Confidencial, Restringida.

Columna	Nivel	Justificación
id	Pública	Identificador del anuncio; no vincula directamente a persona.
neighbourhood	Pública	Granularidad comunal; pública por diseño.
room_type	Pública	Categoría agregada visible en la plataforma.
price	Pública	Precio público del anuncio.
minimum_nights	Pública	Política pública del anuncio.
number_of_reviews	Pública	Métrica agregada.
availability_365	Pública	Disponibilidad pública.
calculated_host_listings_count	Pública	Conteo agregado por anfitrión.
number_of_reviews_ltm	Pública	Métrica agregada últimos 12 meses.
last_review	Interna	Fecha de actividad; revela patrones de uso del anfitrión.
reviews_per_month	Interna	Métrica derivada; revela frecuencia de uso.
name	Confidencial	Texto libre; puede contener dirección, teléfono, correo o RUT.
host_id	Restringida / PII indirecta	Permite cruzar con la API pública de Airbnb para obtener perfil completo del anfitrión.
host_name	Restringida / PII directa	Nombre de persona física; facilita linkage con Conservador de Bienes Raíces.
latitude / longitude	Restringida / PII indirecta	Coordenadas a 6 decimales (~10 cm de precisión); re-identifica la propiedad física.

4.2 PII detectada en texto libre (campo name)

Se aplicaron expresiones regulares adaptadas a Chile para detectar cinco categorías de PII en el campo name:

Tipo de PII	Patrón objetivo	Riesgo
Teléfono chileno	+56 9 XXXX XXXX, 9XXXXXXXXX	Contacto directo fuera de plataforma; viola ToS de Airbnb.
Correo electrónico	user@domain.tld	Canal de comunicación directa; linkage con identidad digital.
RUT chileno	12.345.678-9 / 12345678K	Identificador nacional único; permite cruzar con SII, CMFCHILE.
Handle de redes sociales	@usuario	Re-identificación vía perfil público en Instagram/WhatsApp.

Dirección física	Calle/Av. + número	Re-identificación de propiedad sin necesidad de coordenadas.
------------------	--------------------	--

4.3 Riesgo geográfico por precisión de coordenadas

La norma ISO 6709 establece que 4 decimales de latitud/longitud equivalen a ~11 m de precisión. Con 6 decimales (como en este dataset) la precisión es ~11 cm: suficiente para identificar el apartamento exacto dentro de un edificio mediante geocodificación inversa gratuita (Nominatim/OSM).

Prácticamente el 100 % de los registros del dataset tienen más de 4 decimales.

Recomendación: truncar a 2 decimales (~1.1 km) para uso público.

4.4 Resultados de k-anonymity

La k-anonymity mide cuántos registros comparten exactamente los mismos valores en un conjunto de cuasi-identificadores (QIDs). Si $k=1$, el registro es único y directamente re-identificable.

QIDs seleccionados: neighbourhood, room_type, minimum_nights — todos visibles públicamente en Airbnb.

Umbral objetivo: $k \geq 5$ (análogo al estándar HIPAA para registros de salud; justificado por el nivel de sensibilidad de los datos de ubicación).

Métrica	Antes de remediación	Después de remediación
k mínimo	1 (registros únicos)	≥ 3 (mejorado)
% registros con $k < 5$	Fracción significativa	Reducido tras generalización
Columnas con PII directa	host_name, lat*, lon*	Suprimidas / generalizadas

Nota: l-diversity sobre room_type reveló que la mayoría de clases tienen $l=1$ (todos los registros con los mismos QIDs pertenecen al mismo tipo de cuarto), lo que hace al dataset vulnerable a ataques de homogeneidad incluso si $k>1$. Esto refuerza la necesidad de generalización.

5. Conclusión del Ejercicio Exploratorio

Lo que encontramos, en palabras sencillas.

Airbnb publica datos de sus anuncios en Santiago para fines de investigación urbana. Aunque el archivo parece una simple lista de apartamentos con precios y comunas, contiene información que puede usarse para identificar a personas reales si no se trata correctamente.

Lo que encontramos:

- Los datos tienen buena calidad técnica: no hay precios negativos, ni apartamentos fuera de Santiago, ni IDs repetidos. El problema principal de completitud se explica porque muchos anuncios simplemente nunca han tenido huéspedes.
- El nombre del anfitrión es información personal. En Chile, combinarlo con la dirección de la propiedad (que se puede deducir de las coordenadas del archivo) permite encontrar el nombre completo, el RUT y los datos de propiedad de una persona en registros públicos. Esto es un riesgo real, no hipotético.
- Las coordenadas son demasiado precisas. El archivo guarda la ubicación con tanta exactitud (~10 cm) que se puede identificar no solo el edificio sino el apartamento específico.
- Algunas combinaciones de características (por ejemplo, un tipo de habitación específico con un número de noches mínimas inusual en una comuna pequeña) corresponden a un solo anuncio. Eso significa que aunque quitáramos el nombre del anfitrión, igual se podría saber de quién es.

Por qué importa:

Un archivo que parece público e inofensivo puede convertirse en una herramienta de vigilancia o acoso si no se aplican medidas básicas de protección. Los cambios que proponemos en el Plan de Remediación no reducen la utilidad del dataset para análisis urbanos y de mercado; solo eliminan la información que no aporta valor analítico pero sí expone a las personas.

6. Plan de Remediación Priorizado

Las acciones están ordenadas por nivel de riesgo. Las de riesgo Alto deben aplicarse antes de cualquier distribución del dataset.

Columna(s)	Riesgo	Acción concreta	Justificación (ref.)	Plazo	Resp.
host_name	Alto	Suprimir columna completa del dataset público.	PII directa; facilita linkage con Conservador (§3, §5).	Inmediato	Datos
latitude / longitude	Alto	Truncar a 2 decimales (precisión ~1 km). Alternativa: eliminar ambas columnas.	~100 % de registros con >4 decimales → re-id física (§5).	Inmediato	Ing.
host_id	Medio	Aplicar hash SHA-256 + sal privada. Publicar solo el hash; conservar la tabla de correspondencia bajo acceso restringido.	PII indirecta; permite cruzar con API de Airbnb (§3).	1 sprint	Seg.
name	Medio	Aplicar filtros regex para suprimir tokens PII detectados. Si la tasa de PII detectada supera el 5 %, suprimir la columna completa.	Texto libre con teléfonos, correos, RUT detectados (§3).	1 sprint	D+L
minimum_nights	Bajo	Generalizar en rangos: 1 noche 2–3 4–7 8–30 >30.	Mejora k-anonymity: reduce registros con k<5 (§4).	Próx. ver.	Datos
price	Bajo	Generalizar en bandas de CLP 10.000.	Reduce poder discriminatorio como cuasi-identificador (§4).	Próx. ver.	Datos

6.1 Utilidad analítica tras la remediación

Las acciones anteriores no eliminan el valor del dataset. Los siguientes análisis siguen siendo plenamente posibles:

- Tendencias de precio por comuna y tipo de alojamiento.
- Análisis de disponibilidad y estacionalidad por barrio.
- Comparativas de ocupación aproximada (reviews_per_month) por zona.
- Planificación urbana a nivel comunal.
- Modelos de demanda turística con granularidad suficiente para políticas públicas.

Lo que se pierde: la capacidad de rastrear un anfitrión específico entre plataformas o correlacionar su cartera de propiedades con registros catastrales. Esto es precisamente lo que se debe perder.

Anexo: Reproducibilidad — Cómo Ejecutar el Cuaderno

A.1 Requisitos del entorno

Componente	Versión recomendada	Notas
Python	3.10 o superior	3.9 funciona; <3.9 no garantizado.
pandas	2.x	Usar 2.0+ para evitar FutureWarnings en groupby.
numpy	1.24 o superior	
matplotlib	3.7 o superior	
seaborn	0.12 o superior	
folium	0.14 o superior	Para el mapa interactivo de la Sección 5.
jupyter / jupyterlab	Notebook 6.x o Lab 3.x+	VS Code con extensión Jupyter también funciona.
Conexión a internet	Requerida en primera ejecución	Para descargar el CSV desde Inside Airbnb. Ejecuciones posteriores usan la copia local.

A.2 Instalación de dependencias

Opción 1 — pip (recomendado para entornos simples):

```
pip install pandas numpy matplotlib seaborn folium jupyterlab
```

Opción 2 — conda (recomendado para reproducibilidad estricta):

```
conda create -n airbnb_audit python=3.10
conda activate airbnb_audit
conda install pandas numpy matplotlib seaborn jupyterlab
pip install folium
```

A.3 Ejecución

```
# 1. Clonar o descargar el repositorio con el cuaderno
# 2. Abrir Jupyter
jupyter lab

# 3. En la interfaz, abrir estudio_datosV2.ipynb
# 4. Kernel > Restart & Run All

# La descarga del CSV (~3 MB) ocurre automáticamente en la Sección 1.
# Si el archivo listings.csv ya existe en el mismo directorio, se omite la descarga.
```

A.4 Notas adicionales

- El hash MD5 del CSV se imprime automáticamente. Comparar con la documentación del proyecto para verificar que se usa el mismo snapshot.
- La semilla global `RANDOM_STATE = 42` garantiza reproducibilidad en cualquier operación aleatoria. Si se cambia, los resultados de muestreo pueden variar.
- El mapa interactivo (Sección 5) se guarda como `mapa_ataque_santiago.html` en el directorio de trabajo; abrirlo en cualquier navegador moderno.
- El cuaderno no requiere GPU ni recursos de cómputo especiales; un portátil convencional con 4 GB de RAM es suficiente.
- En entornos con proxy corporativo, configurar las variables de entorno `HTTP_PROXY` y `HTTPS_PROXY` antes de ejecutar la celda de descarga.

— *Fin del informe* —

Universidad EAFIT · Gobernanza de Datos · 2025